

Data Engineer

Fiche missions alternance

Missions professionnelles à privilégier dans le cadre de l'alternance "Data Engineer". Les missions entreprises proposées à l'alternant(e) doivent être en relation directe avec le contenu de sa formation.

A noter : La formation vise l'obtention du titre RNCP40573 "Expert en informatique et systèmes d'information" de niveau (bac +5). Au terme de sa formation en alternance, l'apprenant(e) devra donc être capable de mener à bien les activités types du métier.

Période souhaitée	Activités à privilégier
Court terme	S'intégrer dans l'entreprise - Observer, poser des questions Elaborer et un système de veille réglementaire et technologique - Sélection des sources d'information Manipuler des bases de données SQL et NoSQL - Prétraiter des données (nettoyer, normaliser, gérer les valeurs manquantes) - Interroger un jeu de données via des bibliothèques Python (Pandas, Numpy, Scikit-Learn, ...) Modéliser des données - Transformer des données en représentations graphiques accessibles par tous (Power BI, Dash, Tableau, bibliothèques Python : Matplotlib, Seaborn, Bokeh)
Moyen terme	Contribuer à la gestion d'un projet d'architecture de gestion de données - Participer à la conception, la planification, l'exécution et le suivi du projet - Exploiter des méthodes de projet agiles (Scrum, Kanban, DSDM, XP, ...) Créer et gérer des bases de données SQL et NoSQL - Identifier les différentes sources et types de données - Choisir la solution technique de stockage de données selon l'application - Programmer la sauvegarde des données de l'application - SQL : créer BDD et tables, instructions de manipulation, optimisation des performances (MySQL, PostgreSQL etc.) - NoSQL : requêter, répliquer et mettre à l'échelle (MongoDB etc.) Traiter et analyser de grands volumes de données - Effectuer des opérations de transformation, d'agrégation, d'analyse et de nettoyage sur de grands volumes de données structurées et non structurées (Pyspark) - Créer, manipuler et analyser des graphes (NetworkX) - Exploiter Streamlit pour créer des modélisations de données (DataViz') Gérer des containers - Créer des containers pour préparer le déploiement de l'application - Connecter les containers entre les différents services et au stockage distant - Créer et gérer une architecture microservices Intégrer des données à l'architecture

	• Élaborer des circuits de flux de données sécurisés • Procéder au chargement des données vers les environnements de stockage Automatiser les flux de données • Gérer les versions des fichiers et des modèles (Git / Github) • Automatiser les circuits de collecte, de traitement et de stockage des données de façon sécurisée • Automatiser la gestion lorsqu'une nouvelle version de la solution est proposée • Concevoir et réaliser des tests unitaires Sécuriser la solution • Intégrer les règles garantissant la sécurité de données, des réseaux et des systèmes Exploiter une solution de supervision • En utilisant un système de supervision, qui comprend un serveur, des agents de collecte et une console de supervision, déployer les agents afin de collecter les indicateurs (métriques) précédemment définis • S'assurer que les transactions entre les agents et le serveur sont sécurisées • Définir les valeurs seuils et créer des alarmes pertinentes selon les métriques mesurées • Définir et créer des actions automatiques en réponse à ces alarmes • Lorsque la console fait apparaître un défaut sur un indicateur, déterminer l'origine du problème et quelle équipe sera en mesure d'apporter les mesures correctives. • Régulièrement, rapporter aux développeurs les statistiques de performance de leurs applications en production
Long terme	Gérer un projet d'architecture technique de gestion de données • Contribuer à la conception du projet • Piloter la planification, l'exécution et le suivi du projet en lien avec sa hiérarchie • Exploiter des méthodes de projet agiles (Scrum, Kanban, DSDM, XP) • Prendre en compte les principes et bonnes pratiques en termes d'accessibilité et de sobriété énergétique Développer des composants d'intelligence artificielle • Développer un algorithme d'intelligence artificielle en utilisant des méthodes et outils d'apprentissage supervisé et/ou non supervisé • Identifier et intégrer les enjeux éthiques de la solution développée • Réaliser des tests unitaires • Optimiser le modèle
Tout le long de l'alternance	• Échanger en anglais dans un contexte professionnel Exploiter le système de veille réglementaire et technologique • Analyser et évaluer les résultats de la veille • Diffuser l'information • Maintenir le système de veille à jour (réévaluer les sources, ajuster les critères de recherche)

Le Data Engineer et son contexte professionnel

Le Data Engineer analyse et développe une solution permettant le traitement de volumes importants de données, tout en garantissant la sécurité de celles-ci. Il préconise l'architecture technique nécessaire aux traitements des algorithmes conçus avec le Data Scientist (ex. : puissance de calcul, stockage, flux de données, utilisation des solutions cloud et développements spécifiques).

Déployer et maintenir la solution sur son cycle de vie :

Il est le premier échelon de la chaîne de traitement de données et conçoit des solutions permettant le traitement de volumes importants de "pipelines" de données. Il veille à entretenir une solution permettant le traitement massif de données en utilisant ses diverses expertises. Il anticipe les évolutions dans les données (ex. : variations de volumes ou d'usages) et prépare l'architecture de la plateforme à y répondre techniquement.

Intégrer les technologies du Big Data dans son activité :

Il maîtrise les diverses technologies du Big Data permettant le traitement et la manipulation de données (Hadoop, Spark, Kafka...) ainsi que les langages (Javascript, Scala, Python...), des systèmes d'exploitation (UNIX, Linux,...) et des solutions de base de données (SQL, NO SQL).

Secteurs d'activités

Les solutions de gestion de données concernent l'ensemble des secteurs d'activités (industrie, santé, finance, assurance, organismes publics, services, conseils etc.).

Un Data Engineer peut notamment évoluer dans les secteurs suivants :

- Banque / assurance ;
- Transport et industrie ;
- Cabinets de conseil et cabinet de stratégie numérique / digitale ;
- La transition énergétique ;
- Les plateformes d'e-commerce ;
- La R&D.

Type et taille d'entreprise :

En tant qu'indépendant, il intervient majoritairement sur des projets de plusieurs clients différents. Ses missions sont plus larges en tant qu'indépendant, son expertise est couplée avec les missions du Data Scientist et Data Analyst.

Dans une PME / TPE, chez un éditeur de logiciel, il joue un rôle clé dans la définition et l'évolution du produit/système. La demande de compétences sera ici plus variée et les projets de taille inférieure, en règle générale. Il sera aussi amené à travailler avec des partenaires extérieurs et ainsi maîtriser les règles de fonctionnement de ce type de relation. Dans les petites et moyennes entreprises, le métier est couplé avec celui de Data Scientist et Data Analyst.

Dans une grande Entreprise de Service Numérique, il apporte son expertise technique sur les infrastructures. Il sera ici focalisé sur son périmètre de projet et son expertise métier, souvent de plus grande taille et interne. Le besoin d'expertise métier y sera équivalent dans une structure moyenne ou grande et va intervenir sur des missions en interne et externe.

Type et taille de projet :

Selon la taille de projet, le Data Engineer interviendra sur un ou plusieurs projets avec des équipes projet de différentes tailles. Il travaille en équipe selon la taille du projet et de l'équipe et est lié aux autres métiers de la Data.

Référentiel RNCP40573 - Expert en informatique et systèmes d'information

Bloc de compétences

Définir une stratégie de systèmes d'information

Piloter des projets informatiques

Concevoir et développer une application informatique

Concevoir et déployer des infrastructures DevOps automatisées

Pour plus de d'informations sur le titre RNCP :

<https://www.francecompetences.fr/recherche/rncp/40573/>